

1. Realizar la exploración de los datos correlación, scatter plots, boxplots e histogramas:

1.1. ¿Qué variables son importantes para predecir el valor?

Para saber que variables son importantes primero deberíamos saber a que corresponde cada nombre de las variables para esto miraremos el diccionario que el profesor nos anexo, https://github.com/jdramirez/UCO_ML_AI/blob/master/src/notebook_class/tarea2/data/pruebas_saber/Diccionario%20saber%20pro%202016%20-%202017%20genericas.pdf. Luego de haber revisado cada una de las variables podremos definir y que variables son importantes de manera que las fusionemos/combinemos, un ejemplo de esto es el siguiente:

El puntaje global promedio de los estudiantes que NO son de Colombia pero SI estudiaron en el extranjero es de: 160.5483870967742, y de los que NO son colombianos pero NO estudiaron en el extranjero es de: 149.7841726618705.
El puntaje global promedio de los estudiantes que SI son de Colombia y SI estudiaron en el extranjero es de: 158.97532387415177, y de los que SI son colombianos pero NO estudiaron en el extranjero es de: 149.7841726618705.

Acá podemos ver que la nacionalidad en promedio no tiene importancia para predecir el resultado, pero sí los que estudiaron en el extranjero, ya que los que estudiaron en el extranjero tienden a tener puntajes superiores a 160 puntos.

A continuación verificaremos si el género de una persona es relevante a la hora de predecir el puntaje

```
el puntaje global promedio de las mujeres es de: 142.12944963293006
el puntaje global promedio de las hombres es de: 145.63616814506958
```

En este caso después de analizar, podemos decir que el género no importa para predecir el puntaje global,

Por último para tener un mejor resultado en nuestra predicción lo que hacemos es transformar la información de un variable, en algo que nos sirva y además de esto ver la información que no tiene "sentido", para así imputar o eliminar datos

```
la edad promedio es de: 28.953205772544514
```

```
La edad máxima corregida es: 80.0
```

```
Promedio del puntaje global según rango de edad:
```

	RANGO_EDAD	PROMEDIO_PUNT_GLOBAL
0	<20	144.814815
1	20-23	153.254552
2	24-27	147.287650
3	28-31	138.658363
4	32-35	136.258943
5	36-39	134.866051
6	40-43	134.325682
7	>43	133.134619

Para finalizar con la exploración de datos, para pasar a transformar los datos necesarios a dummies, necesitamos ver el porcentaje de datos faltantes de cada columna(Null), ya que en caso de que la columna sea necesaria para predecir el puntaje, entonces toca imputarla

	Columna	Porcentaje de Valores Nulos
0	ESTU_TIPODOCUMENTO	0.000000
1	ESTU_NACIONALIDAD	0.000000
2	ESTU_GENERO	0.000000
3	ESTU_FECHANACIMIENTO	0.001795
4	ESTU_EXTERIOR	0.000000
5	PERIODO	0.000000
6	ESTU_CONSECUTIVO	0.000000
7	ESTU_ESTUDIANTE	0.000000
8	ESTU_PAIS_RESIDE	0.000000
9	ESTU_DEPTO_RESIDE	0.000000
10	ESTU_COD_RESIDE_DEPTO	0.000000
11	ESTU_MCPIO_RESIDE	0.000000
12	ESTU_COD_RESIDE_MCPIO	0.000000
13	ESTU_AREARESIDE	1.956385
14	ESTU_ESTADOCIVIL	0.242305
15	ESTU_TITULOBTENIDOBACHILLER	2.007538
16	ESTU_VALORMATRICULAUNIVERSIDAD	2.007538
17	ESTU_PAGOMATRICULABECA	2.041640
18	ESTU_PAGOMATRICULACREDITO	2.043435
19	ESTU_PAGOMATRICULAPADRES	2.037153
20	ESTU_PAGOMATRICULAPROPIO	2.031769
21	ESTU_COMOCAPACITOEAMENS B11	1.959975
22	ESTU_CURSODOCENTESIES	94.491609
23	ESTU_CURSOIESAPOYOEXTERNO	94.494301
24	ESTU_CURSOIESEXTERNA	94.495199
25	ESTU_SIMULACROTIPOICFES	94.490712
26	ESTU_ACTIVIDADREFUERZOAREAS	94.490712
27	ESTU_ACTIVIDADREFUERZOGENERIC	94.491609
28	ESTU_TIPODOCUMENTOSB11	2.990218
29	ESTU_SEMESTRECURSA	2.007538
30	FAMI_EDUCACIONPADRE	2.073050
31	FAMI_EDUCACIONMADRE	2.074845
32	FAMI_OCUPACIONPADRE	1.958180
33	FAMI_OCUPACIONMADRE	1.958180
34	FAMI_ESTRATOVIVIENDA	3.623800
35	FAMI_TIENEINTERNET	2.055102
36	FAMI_TIENECOMPUTADOR	2.263304
37	FAMI_TIENELAVADORA	2.280355
38	FAMI_TIENEHORNOMICROOGAS	2.318945
39	FAMI_TIENESERVICIO TV	2.113434
40	FAMI_TIENEAUTOMOVIL	2.380867
41	FAMI_TIENEMOTOCICLETA	2.331509
42	FAMI_TIENECONSOLAVIDEOJUEGOS	2.743426
43	FAMI_TRABAJOLABORPADRE	2.835861
44	FAMI_TRABAJOLABORMADRE	2.738939
45	ESTU_HORASSEMANATRAABA	2.299201
46	FAMI_CUANTOSCOMPARTEBANO	2.597146
47	ESTU_PAGOMATRICULA	2.745221
48	ESTU_VLRULTIMOSEMESCURSO	2.443687
49	ESTU_PRESENTACIONCASA	99.998205
50	ESTU_PRESENTACION SABADO	1.961770
51	INST_COD_INSTITUCION	0.000000
52	INST_NOMBRE_INSTITUCION	0.000000
53	ESTU_PRGM_ACADEMICO	0.000000
54	ESTU_SNIES_PRGMACADEMICO	0.000000
55	GRUPOREFERENCIA	0.716145

Acá observamos que tenemos dos tipos de casos, uno en el que hay columnas con más del 94,49% de datos faltantes, pero que sí tienen una importancia para predecir el puntaje y otro en el que tenemos pocos datos faltantes; en donde hay datos faltantes mayor al 94,49%, aprovechando de que son variables que se resumen en si/no o en grupos 0, 20-40, 40+, vamos a decir que NO y que es 0; en resumen vamos a darle siempre el valor del caso mínimo

Promedio del Puntaje Global según Rango de Edad





Gráfico de Dispersión: Puntaje Global vs. Edad



Siempre que estaba mirando las variables normalmente utilizaba unique, o miraba el promedio y así terminé eligiendo las variables que eran importante, pero en el caso de las del municipio me tocó eliminarla porque la memoria del PC no me permitía continuar para crear las dummies, intenté utilizandi solo las 5 ciudades con mejor promedio y las demás dejádoas por el una variable que llamé "otra", pero lo que provocó es que desmejorara el desempeño del modelo

Después de tener todo lo anterior en cuenta, vamos aplicar los procesos correspondientes para que la aumentar la precisión del algoritmo, entonces primero eliminaremos las columnas que no dan información para predecir el puntaje, luego imputaremos datos, después crearemos las dummies y por último el modelo. vamos a empezar de 0, así tener un flujo ordenado

REGRESIÓN LINEAL

Métricas en Entrenamiento:

R^2 : 0.3009621836832064, MSE: 384.00593407948054, MAPE: 6573108708268.56

Métricas en Prueba:

R^2 : 0.3048825072342758, MSE: 387.89465437207133, MAPE: 59784254987671.195

Aunque el valor de R^2 es de 0.30, lo cual puede considerarse aceptable en un contexto académico, como mencionó el profesor, en un entorno profesional no es suficiente. Este valor indica que el modelo explica aproximadamente el 30% de la variabilidad en los datos, lo que significa que es un modelo deficiente, ya que no logra representar adecuadamente la relación entre las variables y el puntaje general.

En cuanto al MSE, nos da una idea de la diferencia entre las predicciones y los valores reales. Al calcular la raíz cuadrada del MSE, se observa que, en promedio, las predicciones se desvían unas 19.6 unidades de los valores reales, lo cual sugiere que el modelo necesita ser mejorado.

KNN

- **5 vecinos:**

Resultados en Entrenamiento:

R^2 : 0.4234161022269337, MSE: 316.737711567801, MAPE: 5505612036611.183

Resultados en Prueba:

R^2 : 0.14441588650597592, MSE: 477.4394364174805, MAPE: 53996312502620.32

- **10 vecinos:**

Resultados en Entrenamiento:

R^2 : 0.3451853917070672, MSE: 359.7125783999963, MAPE: 5914266763635.34

Resultados en Prueba:

R^2 : 0.20362232023642368, MSE: 444.40062012025476, MAPE: 55330053754556.305

- **20 vecinos:**

Resultados en Entrenamiento:

R^2 : 0.3033320857177435, MSE: 382.7040639614312, MAPE: 6271278310870.73

Resultados en Prueba:

R^2 : 0.23590747166361492, MSE: 426.3846188189883, MAPE: 53228400872717.78

- **30 vecinos:**

Resultados en Entrenamiento:

R^2 : 0.28703098164700014, MSE: 391.6588308554383, MAPE: 6373816218567.269

Resultados en Prueba:

R^2 : 0.24401467450784764, MSE: 421.8605769441742, MAPE: 54306171581352.93

Aquí podemos observar que el menor MSE se dio con el Knn de 30 vecinos, aunque su R^2 no fue el mejor, este KNN fue el que mejor hizo la predicción. En comparación con la Regresión lineal y el KNN, nos dio mucha mejor precisión la regresión lineal.

GBM

Resultados en Entrenamiento:

R^2 : 0.2951, MSE: 387.2219, MAPE: 6647220424267.8643

Resultados en Prueba:

R^2 : 0.2960, MSE: 392.8399, MAPE: 58488796687350.6250

REGRESIÓN LOGÍSTICA

Regresión logítisca

MSE(train): 0.11046172484968142

MSE(test): 0.11267163241496904

Importancia

	Variable	Coeficiente
21	ESTU_INSE_INDIVIDUAL	0.266110
81	ESTU_VLRULTIMOSEMESCURSADO_No pago semestre	0.195276
3	ESTU_AREARESIDE	0.194059
14	FAMI_TIENEHORNOMICROOGAS	0.165948
12	FAMI_TIENECOMPUTADOR	0.164255
...	...	...
15	FAMI_TIENESERVICIOTV	-0.155701
0	ESTU_GENERO	-0.207305
17	FAMI_TIENEMOTOCICLETA	-0.213083
59	FAMI_ESTRATOVIVIENDA_Estrato 1	-0.223989
1	ESTU_FECHANACIMIENTO	-0.498533

Matríz de confusión (Train)

	0	1
0	77562	1164
1	8683	1735

PRECISION: 0.5984822352535357

ACCURACY: 0.8895382751503186

RECALL: 0.16653868304856978

Matríz de confusión (Test)

	0	1
0	19321	305
1	2206	454

PRECISION: 0.5981554677206851

ACCURACY: 0.887328367585031

RECALL: 0.17067669172932332